




3. 遗传算法的变种

堵威

华东理工大学 自动化系

2021.4.1





回顾

- **种群初始化**

- 生成比N多的个体；局部优化；定向初始化

- **终止准则**

- 预定代数、足够好、种群不再改进

- **编码方式**

- 二进制编码、格雷编码

- **精英策略**

- 每一代生成N-E个子代，每一代生成N个子代

- **稳态与代际算法**

- **种群多样性**

- 重复个体，多峰问题，小生境，适应度共享，清理，排挤



本章内容

1. 初始化
2. 收敛准则
3. 编码方式
4. 精英策略
5. 稳态与代际算法
6. 种群多样性
- 7. 选择方案**
8. 交叉
9. 变异



选择方案

- 基本概念

- 在生成子代前，需要进行**选择父代**的操作
- 除轮盘赌选择外，还有很多选择方法，**共同点都是：适应性较强的个体总是比适应性较弱的个体有更大的可能性被选中**
- 选择方法过分偏向适应性强的个体、不能足够地偏向适应性强的个体
- **选择压力**：量化不同选择方法之间的差别


$$\varphi = \text{Pr}(\text{选择适应性最强的个体}) / \text{Pr}(\text{选择平均个体})$$

选择方案

- 随机遍历采样 (Stochastic Universal Sampling)

— 轮盘赌选择：可能会漏掉最好的个体

例：假设选择4个个体进行交叉操作




个体4在4次选择中都没有被选中的概率为： $0.6^4=13\%$

即有1/7的概率会失去种群中最好个体的信息

选择方案

• 随机遍历采样

- 随机遍历采样仍采用轮盘赌方法，但是能解决轮盘赌选择的问题



例：假设选择4个个体进行交叉操作

- 采用带有均匀分布的4个指针的旋转器，旋转一次就能得到4个父代
- 能保证父代中至少一个是个体4，一个是个体3
- 随机遍历采样保证个体 x_i 被选择的次数在 $N_{i,\min}$ 和 $N_{i,\max}$ 之间

$$N_{i,\min} = \left\lfloor \frac{Nf_i}{f_{\text{sum}}} \right\rfloor \quad N_{i,\max} = \left\lceil \frac{Nf_i}{f_{\text{sum}}} \right\rceil$$

- 个体1,2,3和4
- 个体1,3,3和4
- 个体2,3,4和4
- 个体1,3,4和4

选择方案

• 随机遍历采样

– 算法伪代码：从N个个体中随机遍历采样选择N个父代

x_i = 种群中第i个个体, $i \in [1, N]$

$f_i \leftarrow x_i$ 的适应度, $i \in [1, N]$

$f_{\text{sum}} \leftarrow \sum_{i=1}^N f_i$

生成均匀分布随机数 $r \in [0, f_{\text{sum}}/N]$

$f_{\text{accum}} \leftarrow 0$

Parents $\leftarrow \emptyset$

$k \leftarrow 0$

While |Parents| < N

$k \leftarrow k+1$

$f_{\text{accum}} \leftarrow f_{\text{accum}} + f_k$


 While $f_{\text{accum}} > r$

 Parents \leftarrow Parents $\cup x_k$

$r \leftarrow r + f_{\text{sum}}/N$

 End while

下一个父代





选择方案

- 超比例选择

- John Koza在遗传规划的背景下1992年提出
- 在轮盘赌选择的基础上，通过对高适应性个体的适应度值进行不成比例地加权修改
- **核心思想**：适应度缩放，适应性强的个体具有与其适应度不成比例的更大的概率被选中（精确的百分比不那么重要！）
- Koza的版本中：**最好的32%→80%，最差的68%→20%**
- 进化早期，种群适应度值方差大，选择压力可能会过大；进化后期，种群适应度值方差小，额外的选择压力会有好处



选择方案

• Sigma缩放

- 让差别较大的适应度值的选择概率更均衡，让聚在一起的选择概率更分散

将适应度值相对于整个种群的适应度标准差做归一化

$$f'(x_i) = \begin{cases} \max [1 + (f(x_i) - \bar{f}) / (2\sigma), \epsilon] & \text{if } \sigma \neq 0 \\ 1 & \text{if } \sigma = 0 \end{cases}$$

\bar{f} : 适应度的均值, σ : 适应度值的标准差

$$\sigma = \left(\frac{1}{N} \sum_{i=1}^N (f(x_i) - \bar{f})^2 \right)^{1/2} \quad \sigma = \left(\frac{1}{N-1} \sum_{i=1}^N (f(x_i) - \bar{f})^2 \right)^{1/2}$$

ϵ : 用户定义的适应度值在缩放后可允许的非负最小值



选择方案

• Sigma缩放

—例：假设种群中有4个个体，适应度值为

$$f(\mathbf{x}_1) = 10, f(\mathbf{x}_2) = 5, f(\mathbf{x}_3) = 40, f(\mathbf{x}_4) = 15$$

轮盘赌选择中个体的选择概率如下：

$$\Pr(\mathbf{x}_1) = 14\%, \Pr(\mathbf{x}_2) = 7\%, \Pr(\mathbf{x}_3) = 57\%, \Pr(\mathbf{x}_4) = 22\%$$

计算得到适应度值的均值为：17.5，标准差为：15.5，得到缩放后的适应度值为：

$$f'(\mathbf{x}_1) = 0.76, f'(\mathbf{x}_2) = 0.60, f'(\mathbf{x}_3) = 1.72, f'(\mathbf{x}_4) = 0.92$$

轮盘赌选择中个体的选择概率如下：

$$\Pr(\mathbf{x}_1) = 19\%, \Pr(\mathbf{x}_2) = 15\%, \Pr(\mathbf{x}_3) = 43\%, \Pr(\mathbf{x}_4) = 23\%$$



选择方案

- Sigma缩放

—例：假设种群中有4个个体，适应度值为

$$f(\mathbf{x}_1) = 15, f(\mathbf{x}_2) = 25, f(\mathbf{x}_3) = 20, f(\mathbf{x}_4) = 10$$

轮盘赌选择中个体的选择概率如下：

$$\Pr(\mathbf{x}_1) = 21\%, \Pr(\mathbf{x}_2) = 36\%, \Pr(\mathbf{x}_3) = 29\%, \Pr(\mathbf{x}_4) = 14\%$$

计算得到适应度值的均值为：17.5，标准差为：6.5，得到缩放后的适应度值为：

$$f'(\mathbf{x}_1) = 0.81, f'(\mathbf{x}_2) = 1.58, f'(\mathbf{x}_3) = 1.19, f'(\mathbf{x}_4) = 0.42$$

轮盘赌选择中个体的选择概率如下：

$$\Pr(\mathbf{x}_1) = 20\%, \Pr(\mathbf{x}_2) = 40\%, \Pr(\mathbf{x}_3) = 30\%, \Pr(\mathbf{x}_4) = 10\%$$



选择方案

- 基于排名选择

- 基于适应度值的排名选择，不是基于适应度值选择
- 将种群中的个体按适应度值从最好到最差排序，最好的个体排名为N（种群规模），最差的个体排名为1
- 例：某最大化问题中，种群适应度值为

$$f(\mathbf{x}_1) = 15, f(\mathbf{x}_2) = 25, f(\mathbf{x}_3) = 20, f(\mathbf{x}_4) = 10$$

则排名为：

$$R(\mathbf{x}_1) = 2, R(\mathbf{x}_2) = 4, R(\mathbf{x}_3) = 3, R(\mathbf{x}_4) = 1$$



选择方案

- 基于排名选择

—例：某最小化问题中，种群适应度值为

$$f(\mathbf{x}_1) = 15, f(\mathbf{x}_2) = 25, f(\mathbf{x}_3) = 20, f(\mathbf{x}_4) = 10$$

基于排名的选择概率如下：

$$\Pr(\mathbf{x}_1) = 20\%, \Pr(\mathbf{x}_2) = 40\%, \Pr(\mathbf{x}_3) = 30\%, \Pr(\mathbf{x}_4) = 10\%$$

轮盘赌选择中个体的选择概率如下：

$$\Pr(\mathbf{x}_1) = 21\%, \Pr(\mathbf{x}_2) = 36\%, \Pr(\mathbf{x}_3) = 29\%, \Pr(\mathbf{x}_4) = 14\%$$

当适应度值聚在一起时，**基于排名选择会分散选择概率**，在进化算法运行的后期，种群开始收敛时，相似的个体之间会有较大的区别



选择方案

- 基于排名选择

- 也可以用非线性函数让排名变换，调整选择概率的分散程度，如取排名的平方：

$$R(\mathbf{x}_1) = 4, R(\mathbf{x}_2) = 16, R(\mathbf{x}_3) = 9, R(\mathbf{x}_4) = 1$$

则选择概率为：

$$\Pr(\mathbf{x}_1) = 13\%, \Pr(\mathbf{x}_2) = 53\%, \Pr(\mathbf{x}_3) = 40\%, \Pr(\mathbf{x}_4) = 4\%$$

- 排名的平方：分散
- 排名的平方根：均匀


选择方案

• 线性排名

—是基于排名选择的一般化，在线性排名中将选择个体 x_i 的概率设置为：

$$\text{Pr}(x_i) = \alpha + \beta R(x_i)$$


$R(x_i)$ 是 x_i 的排名， α 和 β 是自定义参数。



左图中，种群规模为N的进化算法中选择的线性排名方法（最差个体排名为1，最好个体排名为N）

选择方案

• 线性排名



左图：最差个体排名为1，最好个体排名为N，平均个体排名为 $(N+1)/2$ ，选择压力为：

$$\phi = \frac{\alpha + \beta N}{\alpha + \beta(N+1)/2}$$

将选择概率做归一化处理，让它们的总和为1，得到：


$$\sum_{i=1}^N (\alpha + \beta i) = \alpha N + \beta N(N+1)/2 = 1$$

如果想让选择压力为 ϕ ，可以求得：

$$\alpha = \frac{2N - \phi(N+1)}{N(N-1)} \quad \beta = \frac{2(\phi - 1)}{N(N-1)}$$

选择方案

• 线性排名



$Pr(x_i)$ 是 $R(x_i)$ 的线性函数，有：

$$Pr(\text{平均的 } x) = 1/2[Pr(\text{最差的 } x) + Pr(\text{最好的 } x)] \geq 1/2 Pr(\text{最好的 } x)$$

则：

$$\phi = Pr(\text{最好的 } x) / Pr(\text{平均的 } x) \leq 2$$

如果能让 $\phi > 2$ ，则 $Pr(\text{最差的 } x)$ 为负

在进化算法早期，通常想让选择压力较小以避免过早收敛，
在后期让选择压力较大以便利用适应性强的个体。

选择方案

• 锦标赛选择

- 每次从种群中取出一定数量个体，然后选择其中最好的一个进入父代种群。重复该操作，直到新的种群规模达到原来的种群规模。



1. 确定每次选择的个体数量，一般选择2个；
2. 从种群中随机选择2个个体(每个个体入选概率相同) 构成组，根据每个个体的适应度值，选择其中适应度值最好的个体进入父代种群；
3. 重复步骤(2)，直至得到的个体构成新一代种群。

选择的个体越多，选择压力越大/越小？

选择方案

- 种马遗传算法

- 经典遗传算法选择交叉的父代：依据概率

- **种马遗传算法**：每次交叉操作始终选择每一代最好的个体
(种马：每一代最好的个体)

- **个体1：种马**

- 个体2：正常的方式选择（基于适应度选择、基于排名选择、锦标赛选择、...）





选择方案

• 种马遗传算法

种马遗传算法的伪代码:

Parents \rightarrow {随机生成的种群}

While not (终止准则)

 计算种群中每个父代的适应度

 Children $\leftarrow \emptyset$

$x_1 \leftarrow$ 适应性最强的父代

 While |Children| < |Parents|

 用适应度根据概率选择出第二个父代 x_2 , $x_2 \neq x_1$

 父代交叉生成子代 c_1 和 c_2

 Children \leftarrow Children $\cup \{c_1, c_2\}$

 Loop

 一些子代随机变异

 Parents \leftarrow Children

下一代



选择方案

• 种马遗传算法

- 例：选出一组20维的测试问题，测试采用种马方案和不采用种马方案的连续遗传算法。种群规模为50，代数为50，变异率为1%，使用参数为2的精英策略

测试函数	非种马	种马算法
------	-----	------

Ackley	1.44	1
Fletcher	3.26	1
Griewank	3.96	1
Penalty #1	1.05×10^5	1
Penalty #2	160.8	1
Quartic	9.14	1
Rastrigin	1.92	1
Rosenbrock	3.89	1
Schwefel 1.2	1.24	1
Schwefel 2.21	1.65	1
Schwefel 2.22	3.70	1
Schwefel 2.26	2.56	1
Sphere	4.47	1
Step	4.23	1

对于这一组基准，种马遗传
算法明显优于标准遗传算法



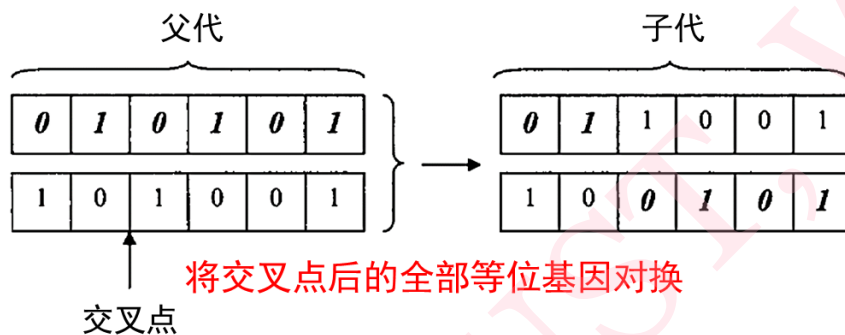
本章内容

1. 初始化
2. 收敛准则
3. 编码方式
4. 精英策略
5. 稳态与代际算法
6. 种群多样性
7. 选择方案
- 8. 交叉**
9. 变异

交叉

• 基本概念

— 简单的遗传算法采用单点交叉



— 还有其他交叉方法

— 假设种群为 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$, 父代个体 $\mathbf{x}_i = [x_i(1), x_i(2), \dots, x_i(n)]$,
子代 $y = [y(1), y(2), \dots, y(n)]$



交叉

- 单点交叉（二进制或连续算法） Single-point crossover

- 假设有两个父代 \mathbf{x}_a 和 \mathbf{x}_b

$$\mathbf{x}_a = [x_a(1), x_a(2), \dots, x_a(n)]$$

$$\mathbf{x}_b = [x_b(1), x_b(2), \dots, x_b(n)]$$

- m 是随机选出的交叉点

$$\begin{array}{lcl} y_1(k) & \leftarrow & [x_a(1) \quad \cdots \quad x_a(m) \quad | \quad x_b(m+1) \quad \cdots \quad x_b(n)] \\ y_2(k) & \leftarrow & [x_b(1) \quad \cdots \quad x_b(m) \quad | \quad x_a(m+1) \quad \cdots \quad x_a(n)] \end{array}$$

- 如果 $m=0$ ，子代 \mathbf{y} 是 \mathbf{x}_b 的克隆；如果 $m=n$ ，子代子代 \mathbf{y} 是 \mathbf{x}_a 的克隆



交叉

- 多点交叉（二进制或连续算法） Multi-point crossover

- 多个交叉点

- 假设有两个父代 \mathbf{x}_a 和 \mathbf{x}_b

$$\mathbf{x}_a = [x_a(1), x_a(2), \dots, x_a(n)]$$

$$\mathbf{x}_b = [x_b(1), x_b(2), \dots, x_b(n)]$$

- 交叉点为 m_1 和 m_2 的两点交叉：

$$y(k) \leftarrow [x_a(1) \cdots x_a(m_1) \mid x_b(m_1 + 1) \cdots x_b(m_2) \mid x_a(m_2 + 1) \cdots x_a(n)]$$



交叉

- 分段交叉（二进制或连续算法） Segmented crossover

- 分段交叉可以看成是多点交叉的一般化
- 子代1从父代1获得它的第一个特征；然后以概率 p 切换到父代2取得子代1的第二个特征，以 $1-p$ 的概率从父代1取得子代1的第二个特征
- 每次得到子代1的一个特征，就从概率 p 切换到另一个父代取得下一个特征
- 如果子代1从父代1得到特征 k ，则子代2从父代2得到特征 k
- 切换概率 p 通常取0.2



交叉

- 分段交叉（二进制或连续算法） Segmented crossover

```
 $S \leftarrow \text{true}$   
For  $k = 1$  to  $n$   
  If  $S$  then  
     $c_1(k) \leftarrow p_1(k)$   
     $c_2(k) \leftarrow p_2(k)$   
  else  
     $c_1(k) \leftarrow p_2(k)$   
     $c_2(k) \leftarrow p_1(k)$   
  End if  
   $r \leftarrow U[0, 1]$   
  If  $r < \rho$  then  $S \leftarrow \text{not } S$   
Next solution feature
```



交叉

- 均匀交叉（二进制或连续算法） Uniform crossover

- 假设有两个父代 \mathbf{x}_a 和 \mathbf{x}_b ，均匀交叉得到子代 y ，其中对每个 $k \in [1, n]$, y 的第 k 个特征为：

$$y(k) \leftarrow x_{i(k)}(k)$$

这里从集合 $\{a, b\}$ 随机地选择 $i(k)$ ，即随机地以50%的概率从它的两个父代选择每一个子代的特征

- 多父代交叉（二进制或连续算法） Multi-parent crossover

- 又被称为基因库重组、扫描交叉、多性交叉；是均匀交叉的一般化



交叉

- 多父代交叉（二进制或连续算法） Multi-parent crossover

- 在多父代交叉中，当父代的个数大于2时，从父代随机选择每一个子代的特征
- 对于每一个 $k \in [1, n]$ ，由多父代交叉得到：

$$y(k) \leftarrow x_{i(k)}(k)$$

说明：在这里，随机地从 $[1, N]$ 的子集中选择 $i(k)$ ，在实施多父代交叉时，需注意：

在潜在父代的池子（pool）里应该有多少个体？

应该如何为这个池子选择个体？

池子确定后，如何从池子中选父代？



交叉

- 全局均匀交叉（二进制或连续算法） Global uniform crossover

- 多父代交叉的一个特例，此时的父代池为整个种群
- 对于每一个 $k \in [1, n]$ ，由全局均匀交叉得到：

$$y(k) \leftarrow x_{i(k)}(k)$$

其中对每一个 k 随机选择在 $[1, N]$ 上均匀分布的 $i(k)$ ；也可以基于适应度来选 $i(k)$ ，即对所有 $k \in [1, n]$ 和 $m \in [1, N]$ ， $i(k)=m$ 的概率可以与 \mathbf{x}_m 的适应度成正比

交叉

- 洗牌交叉（二进制或连续算法） Shuffle crossover

- 洗牌交叉将父代的解的特征**随机重新排列**
- 在为给定的子代提供解的特征的所有父代中，解的特征用相同的方式重排，然后采用前面的交叉方法（通常单点交叉）得到子代，再撤除对子代解的特征的重排





交叉

• 洗牌交叉（二进制或连续算法） Shuffle crossover

– 算法：n维父代与单点交叉结合的洗牌交叉算法

$\{r_1, r_2, \dots, r_n\} \leftarrow \{1, 2, \dots, n\}$ 的一个随机排列

交叉点 $m \leftarrow U[1, n-1]$

For $k = 1$ to m

$t_1(k) \leftarrow p_1(r_k)$

$t_2(k) \leftarrow p_2(r_k)$

下一个 k

For $k = m+1$ to n

$t_1(k) \leftarrow p_2(r_k)$

$t_2(k) \leftarrow p_1(r_k)$

下一个 k

For $k = 1$ to n

$c_1(r_k) \leftarrow t_1(k)$

$c_2(r_k) \leftarrow t_2(k)$

下一个 k

p_1, p_2 : 两个父代

t_1, t_2 : 撤除洗牌前的两个子代

c_1, c_2 : 撤除洗牌后的两个子代



交叉

- 平交叉/算术交叉（连续算法） Flat/Arithmetic crossover

- 平交叉，也称为算术交叉，描述如下：

$$y(k) \leftarrow U[x_a(k), x_b(k)] = \alpha x_a(k) + (1-\alpha)x_b(k)$$

其中， $\alpha \sim U[0,1]$ ，即 $y(k)$ 是来自两个父代第 k 个特征之间均匀分布的随机数（两个父代特征的线性组合）

- 平交叉和算术交叉的区别所在：

平交叉得到一个子代，算术交叉得到两个子代

$$y(k) = \alpha x_a(k) + (1-\alpha)x_b(k)$$

$$y_1(k) = \alpha x_a(k) + (1-\alpha)x_b(k)$$

$$y_2(k) = (1-\alpha) x_a(k) + \alpha x_b(k)$$



交叉

- 混合交叉（连续算法） Blended crossover

-混合交叉，也称为BLX- α 交叉和启发式交叉，描述如下：

$$x_{\min}(k) \leftarrow \min(x_a(k), x_b(k)), x_{\max}(k) \leftarrow \max(x_a(k), x_b(k))$$

$$\Delta x(k) \leftarrow x_{\max}(k) - x_{\min}(k), y(k) \leftarrow U[x_{\min}(k) - \alpha \Delta x(k), x_{\max}(k) + \alpha \Delta x(k)]$$

α 是用户定义的参数

若 $\alpha=0$ ，混合交叉等价于平交叉

若 $\alpha<0$ ，混合交叉会让搜索域缩小，利于种群开发

若 $\alpha>0$ ，混合交叉会让搜索域扩大，利于探索

建议 $\alpha=0.5$



交叉

- 线性交叉（连续算法） Linear crossover

- 线性交叉由父代 \mathbf{x}_a 和 \mathbf{x}_b 生成3个后代：

$$y_1(k) \leftarrow (1/2)x_a(k) + (1/2)x_b(k)$$

$$y_2(k) \leftarrow (3/2)x_a(k) - (1/2)x_b(k)$$

$$y_3(k) \leftarrow (-1/2)x_a(k) + (3/2)x_b(k)$$

为下一代保留这3个后代中适应性最强的一个，或适应性最强的两个



交叉

- 模拟二进制交叉（连续算法） Simulated binary crossover (SBX)

– SBX由父代 \mathbf{x}_a 和 \mathbf{x}_b 生成2个后代：

$$y_1(k) \leftarrow (1/2)[(1-\beta_k)x_a(k)+(1+\beta_k)x_b(k)]$$

$$y_2(k) \leftarrow (1/2)[(1+\beta_k)x_a(k)+(1-\beta_k)x_b(k)]$$

β_k 为由下面的概率密度函数生成的随机数：

$$\text{PDF}(\beta) = (1/2)(\eta+1) \beta^\eta, \text{ 如果 } 0 \leq \beta \leq 1$$

$$\text{PDF}(\beta) = (1/2)(\eta+1) \beta^{-(\eta+2)}, \text{ 如果 } \beta > 1$$

η 是任意的非负实数，推荐 η 取0~5.



交叉

• 小结

- **二进制/连续算法**：单点交叉、多点交叉、分段交叉、均匀交叉、多父代交叉、全局均匀交叉、洗牌交叉
- **连续算法**：平交叉/算术交叉，混合交叉，线性交叉，模拟二进制交叉
- 原本都是针对遗传算法提出的，但是也可以用于别的进化算法
- 这些算法没有绝对的最优者：某个交叉方法可能在一个问题上最好，而另一个交叉方法在另一个问题上最好
- 单点交叉的性能可以认为最差



本章内容

1. 初始化
2. 收敛准则
3. 编码方式
4. 精英策略
5. 稳态与代际算法
6. 种群多样性
7. 选择方案
8. 交叉
- 9. 变异**



变异

• 背景知识

- 二进制算法中，变异是一个简单的操作，每一个个体有 n 位，变异率为 ρ （以概率 ρ 翻转每一个个体的每一位）
- 连续算法中，对每一个 i 和每一个 k 以概率 ρ 修改 $x_i(k)$ ，如何修改？
- **方式1**：采用以搜索域中心为均值的均匀分布或高斯分布生成 $x_i(k)$
- **方式2**：以非变异的 $x_i(k)$ 的值为均值的均匀分布和高斯分布生成 $x_i(k)$



变异

- 以 $x_i(k)$ 为中心的均匀变异

– 对于 $i \in [1, N]$ 和 $k \in [1, n]$, 以 $x_i(k)$ 为中心的均匀变异可以写成:

$$r \leftarrow U[0, 1]$$
$$x_i(k) \leftarrow \begin{cases} x_i(k) & \text{if } r \geq \rho \\ U[x_i(k) - \alpha_i(k), x_i(k) + \alpha_i(k)] & \text{if } r < \rho \end{cases}$$

其中 $\alpha_i(k)$ 是用户定义参数, 它确定变异的大小: 通常选择尽可能大的 $\alpha_i(k)$ 同时保证变异仍在搜索域内:

$$\alpha_i(k) = \min(x_i(k) - x_{\min}(k), x_{\max}(k) - x_i(k))$$



变异

- 以搜索域的中央为中心的均匀变异

- 对于 $i \in [1, N]$ 和 $k \in [1, n]$, 以搜索域的中央为均匀变异可以写成:

$$\begin{aligned} r &\leftarrow U[0, 1] \\ x_i(k) &\leftarrow \begin{cases} x_i(k) & \text{if } r \geq \rho \\ U[x_{\min}(k), x_{\max}(k)] & \text{if } r < \rho \end{cases} \end{aligned}$$



变异

- 以 $x_i(k)$ 为中心的高斯变异

– 对于 $i \in [1, N]$ 和 $k \in [1, n]$, 以 $x_i(k)$ 为中心的高斯变异可以写成:

$$r \leftarrow U[0, 1]$$
$$x_i(k) \leftarrow \begin{cases} x_i(k) & \text{if } r \geq \rho \\ \max [\min(x_{\max}(k), N(x_i(k), \sigma_i^2(k)), x_{\min}(k))] & \text{if } r < \rho \end{cases}$$

其中, $\sigma_i(k)$ 是用户定义的参数, 与变异的大小成正比。min和max的运算保证 $x_i(k)$ 变异后的值留在搜索域中。



变异

- 以搜索域的中央为中心的高斯变异

-对于 $i \in [1, N]$ 和 $k \in [1, n]$, 以搜索域的中央为中心的高斯变异可以写成:

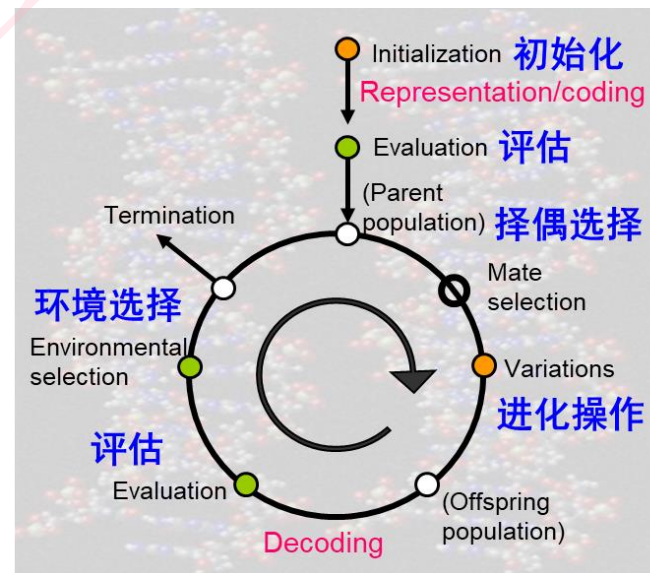
$$r \leftarrow U[0, 1]$$
$$x_i(k) \leftarrow \begin{cases} x_i(k) & \text{if } r \geq \rho \\ \max [\min(x_{\max}(k), N(c_i(k), \sigma_i^2(k))), x_{\min}(k)] & \text{if } r < \rho \end{cases}$$

其中, $c_i(k) = (x_{\min}(k) + x_{\max}(k)) / 2$ 是搜索域的中央, $\sigma_i(k)$ 是用户定义参数, 与变异的大小成正比。min和max的运算保证 $x_i(k)$ 变异后的值留在搜索域中。

变异

• 本章总结

- 讨论了遗传算法/进化算法的常用变种
- 初始化, 收敛准则, 格雷编码, 精英策略, 稳态与代际算法, 种群多样性, 选择, 交叉, 变异
- 还有其他变种: 种群规模、交互的子种群
- 进化算法是一个通用的框架, 定义优化方法, 包括候选解的种群、选择、交叉和变异





结束

