




# 10. 约束优化

堵威

华东理工大学 自动化系

2021.5.6





# 回顾

## —多目标优化

实际优化问题通常包含多个目标，这些目标互相冲突

## —Pareto最优性

**支配：**称 $\mathbf{x}^*$ 支配 $\mathbf{x}$ ，如果下面的两个条件成立：(1) 对所有 $i \in [1, k]$ ， $f_i(\mathbf{x}^*) \leq f_i(\mathbf{x})$ ；(2) 对至少一个 $j \in [1, k]$ ， $f_j(\mathbf{x}^*) < f_j(\mathbf{x})$ ，即对于所有目标函数值， $\mathbf{x}^*$ 至少与 $\mathbf{x}$ 一样好，并且至少有一个目标函数值比 $\mathbf{x}$ 好，记为 $\mathbf{x}^* \prec \mathbf{x}$ 。

非支配、Pareto最优点、Pareto最优集、Pareto前沿

## —评判Pareto解集优劣的指标

超体积HV，反世代距离IGD



# 回顾

---

- 非支配排序遗传算法、改进的非支配排序遗传算法

- Nondominated sorting genetic algorithm-II, NSGA-II

- 迄今为止最经典的进化多目标优化算法（IEEE Transactions on Evolutionary Computation, 2002, 6(2): 182-197）

- 针对NSGA进行的3大改进之处：

- 1) 快速非支配排序方法（fast nondominated sorting approach）

- 2) 个体拥挤距离算子（crowding distance-based operator）


- 3) 精英策略选择算子（elitism strategy-based selection operator）


# 回顾

## • 改进的非支配排序遗传算法

– NSGA-II:

- 1) 快速非支配排序方法 (fast nondominated sorting approach)
- 2) 个体拥挤距离算子 (crowding distance-based operator)
- 3) 精英策略选择算子 (elitism strategy-based selection operator)






# 本章内容

---

1. 背景知识
2. 罚函数法
3. 处理约束的常用方法



# 本章内容

---

**1. 背景知识**


2. 罚函数法

3. 处理约束的常用方法

# 背景知识

## • 约束优化

- 对于实际中的优化问题，基本都会**带有约束**
- 如上班怎么选择乘车路线，才能舒服又快速的到达公司？比如约束条件可能包括：总花费、出发和到达时间等
- 生产线加工订单，如何最快地加工完所有订单？约束条件可能包括：产能限制、生产线匹配等





# 背景知识

## • 约束优化

– 约束优化问题可以写成：

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad \left. \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i \in [1, m], \\ \text{且} \quad h_j(\mathbf{x}) = 0, \quad j \in [1, p]. \end{array} \right\}$$

这个问题包含 $m+p$ 个约束，其中 $m$ 个不等式约束， $p$ 个等式约束。满足所有约束的 $\mathbf{x}$ 的集合称为可行集，违反一个或多个约束的 $\mathbf{x}$ 的集合被称为不可行集：

可行集 $\mathcal{F} = \{\mathbf{x} : g_i(\mathbf{x}) \leq 0, \quad i \in [1, m] \text{ 且 } h_j(\mathbf{x}) = 0, \quad j \in [1, p]\}$ ,

不可行集 $\bar{\mathcal{F}} = \{\mathbf{x} : \mathbf{x} \notin \mathcal{F}\}$ .

为求解上式优化问题而设计的进化算法被称为**约束进化算法**。





# 背景知识

## • 约束进化算法

### – 罚函数法：

基于个体 $x$ 违反约束的程度修改它的目标函数（适应度值）。

- 容许甚至鼓励种群中的不可行解的罚函数法被称为**外点法**，它们会在目标函数（适应度值）或选择上惩罚不可行候选解。
- 不容许种群中出现不可行解的罚函数法称为**内点法**。

### – 特殊表示：


将问题表示为无约束的，但候选解仍然带约束。

### – 修补算法：

修补不可行的个体让它们变为可行的。

### – 混合方法：

上述方法的结合，或与非进化算法结合。



# 本章内容

---

1. 背景知识

**2. 罚函数法**

3. 处理约束的常用方法



# 罚函数法

## • 基本概念

- 罚函数法惩罚违反约束或接近违反约束的候选解
- 1943年, Richard Courant 首先提出罚函数法
- 罚函数法是最常用的求解约束优化的方法
- 两种方法设计罚函数法:
  - 1) 内点法: 在可行个体靠近约束的边界时就惩罚它, 不容许种群中出现不可行个体;
  - 2) 外点法: 容许种群中存在不可行个体, 但在适应度值上惩罚它们, 或在为下一代选择父代的时候惩罚它们



# 罚函数法

## • 内点法

– 内点法在种群中只容许可行个体，当可行个体靠近约束的边界时，会在适应度值上惩罚个体以鼓励个体留在可行范围之内

– 例：考虑问题

$$\min f(x) = x^2, \quad \text{s.t. } x \geq c$$

可以修改这个问题，当x的可行值靠近约束时就惩罚它。修改后的函数被称为罚函数。如将该问题转化为无约束问题：

$$\min f'(x) = x^2 + (x - c + \delta)^{-\alpha}$$


其中， $\delta > 0$ 是一个小的常数， $\alpha > 0$ 是另一个常数，当 $\alpha \rightarrow 0$ 时， $\arg\min_x f'(x) \rightarrow \arg\min_x f(x)$

# 罚函数法

- 内点法

$$f(x)=x^2, \quad f'(x)=x^2+(x-c+\delta)^{-\alpha}$$

画出 $c=1$ ,  $\delta=0.01$ 且 $\alpha=1$ 时的 $f(x)$ 和 $f'(x)$




想要最小化 $f(x)$ 并且 $x \geq 1$ , 用内点法将带约束的最小化 $f(x)$ 转化为无约束的最小化 $f'(x)$

# 罚函数法

## • 内点法

– 在约束进化算法中，常常不用内点法，原因如下：

- 1) 对于许多约束优化问题，要找出满足所有约束的候选解是一件极具挑战性的问题；
- 2) 不可行解包含的信息可能有利于搜索带约束的最优值



大搜索空间中小可行集 $F$ 的例子。要直接找到候选解 $x \in F$  可能较难，但找到两个不可行个体 $x_1$ 和 $x_2$ ，由它们组合生成可行个体也许很容易



# 罚函数法

---

## • 外点法

- 外点法容许种群中存在不可行个体，但要在适应度值上或选择概率上惩罚它们
- 死刑法：死刑法在种群中容许不可行个体，但只是短暂地容许。死刑法会立即去掉种群中的不可行个体 $x$ ，如果是通过交叉得到的 $x$ ，就拒绝它并再进行交叉直到得到可行个体；如果是通过变异得到的 $x$ ，就拒绝它直到得到可行个体
- 非死刑法：是比死刑法更宽容的外点法，在进化算法的整个过程中都容许不可行个体留在种群中

# 罚函数法

## • 外点法

- **非死刑法**：是比死刑法更宽容的外点法，在进化算法的整个过程中都容许不可行个体留在种群中
- 将标准约束问题转化为下面的无约束问题：

$$\left. \begin{aligned} \min_{\mathbf{x}} \phi(\mathbf{x}), \text{ 这里 } \phi(\mathbf{x}) &= f(\mathbf{x}) + \sum_{i=1}^m r_i G_i(\mathbf{x}) + \sum_{j=1}^p c_j L_j(\mathbf{x}) \\ G_i(\mathbf{x}) &= [\max\{0, g_i(\mathbf{x})\}]^\beta, \\ L_j(\mathbf{x}) &= |h_j(\mathbf{x})|^\gamma, \end{aligned} \right\}$$

违反约束的程度

其中， $r_i$ 和 $c_j$ 为正数，称为**惩罚因子**； $\beta$ 和 $\gamma$ 是正数，通常设为1或2。 $\phi(\mathbf{x})$ 通常被称为**惩罚适应度函数**。如果 $\mathbf{x} \in F$ ，则 $\phi(\mathbf{x})=f(\mathbf{x})$ ；如果 $\mathbf{x} \notin F$ ，则 $\phi(\mathbf{x})>f(\mathbf{x})$ 的量会随着违反约束的量的增大而增大。





# 罚函数法


## • 外点法

- 有了惩罚适应度函数 $\varphi(\mathbf{x})$ ，就以 $\varphi(\mathbf{x})$ 作为适应度函数运行优化算法选择下一代个体，因此，可以将无约束优化进化算法扩展到约束优化
- 约束 $h_j(\mathbf{x})=0$ 很苛刻，如果在连续搜索域上随机生成一个初始种群，所得的个体能满足约束的可能性基本为0，因此常将等式的硬约束转化为要求 $h_j(\mathbf{x})$ 几乎为0而不是正好为0的软约束：

$$|h_j(\mathbf{x})| \leq \varepsilon$$

$\varepsilon$ 为一个小的正数，等价于：

$$h_j(\mathbf{x}) - \varepsilon \leq 0, -h_j(\mathbf{x}) - \varepsilon \leq 0$$



# 本章内容

---

1. 背景知识

2. 罚函数法

**3. 处理约束的常用方法**



# 处理约束的常用方法

---

## • 概述

– 介绍进化算法常用的处理约束的几种方法，都属于非死刑法

- 1) 静态惩罚方法
- 2) 可行点优势
- 3) 折中进化算法
- 4) 协同进化惩罚
- 5) 动态惩罚方法
- 6) 自适应惩罚方法
- 7) 自身自适应罚函数
- 8) 随机排名
- 9) 小生境惩罚方法

.....

# 处理约束的常用方法

## • 静态惩罚方法

– 将等式约束转换为不等式约束：

$$\min_{\mathbf{x}} \phi(\mathbf{x}), \text{ 这里 } \phi(\mathbf{x}) = f(\mathbf{x}) + \sum_{i=1}^{m+p} r_i G_i(\mathbf{x})$$
$$G_i(\mathbf{x}) = \left\{ \begin{array}{ll} (\max\{0, g_i(\mathbf{x})\})^\beta, & i \in [1, m], \\ (\max\{0, |h_i(\mathbf{x})| - \epsilon\})^\beta, & i \in [m+1, m+p]. \end{array} \right\}$$

取 $\beta=2$ ， $r_i$ 是违反约束程度的函数，即 $r_i$ 是 $G_i(\mathbf{x})$ 的一个非减函数，根据违反约束的量，惩罚因子 $r_i$ 可在一个离散值集合中取值：

$$r_i = \left\{ \begin{array}{ll} R_{i1}, & \text{如果 } G_i(\mathbf{x}) \in (0, T_{i1}], \\ R_{i2}, & \text{如果 } G_i(\mathbf{x}) \in (T_{i1}, T_{i2}], \\ \vdots & \\ R_{iq}, & \text{如果 } G_i(\mathbf{x}) \in (T_{i,q-1}, \infty), \end{array} \right.$$

$q$ 是用户指定的约束水平的个数， $R_{ij}$ 是用户定义的权重， $T_{ij}$ 是用户定义的约束阈值。

# 处理约束的常用方法

## • 动态惩罚方法

– 将等式约束转换为不等式约束：

$$\left. \begin{aligned} \min_{\mathbf{x}} \phi(\mathbf{x}), \text{ 这里 } \phi(\mathbf{x}) &= f(\mathbf{x}) + \sum_{i=1}^{m+p} r_i G_i(\mathbf{x}) \\ G_i(\mathbf{x}) &= \begin{cases} (\max\{0, g_i(\mathbf{x})\})^\beta, & i \in [1, m], \\ (\max\{0, |h_i(\mathbf{x})| - \epsilon\})^\beta, & i \in [m+1, m+p]. \end{cases} \end{aligned} \right\}$$

取 $r_i = (ct)^\alpha$ ，这里 $c$ 和 $\alpha$ 为常数， $t$ 为代数：

通常 $c$ 取1/2,  $\alpha$ 取1或2

$$\left. \begin{aligned} \phi(\mathbf{x}) &= f(\mathbf{x}) + (ct)^\alpha M(\mathbf{x}), \\ M(\mathbf{x}) &= \sum_{i=1}^{m+p} G_i(\mathbf{x}). \end{aligned} \right\}$$

约束的惩罚随着代数增加。



# 处理约束的常用方法

## • 自适应惩罚方法

– 利用种群的反馈调整惩罚权重，将权重设为：

$$r_i(t+1) = \begin{cases} r_i(t)/\beta_1, & \text{如果是情况1,} \\ \beta_2 r_i(t), & \text{如果是情况2,} \\ r_i(t), & \text{其他,} \end{cases}$$

其中 $t$ 为代数， $\beta_1$ 和 $\beta_2$ 是满足 $\beta_1 > \beta_2 > 1$ 的常数。**情况1**意味着最好的个体在过去 $k$ 代的每一代都是可行的，**情况2**意味着在过去的 $k$ 代都没有可行个体；

– 如果种群中最好的个体可行，减小约束权重就会容许种群中有更多不可行个体；如果种群中没有可行个体，增大约束权重有利于获得一些可行个体。



# 处理约束的常用方法

## • 随机排名

- 在约束进化算法中**加入随机成分**：有时根据适应度值对候选解排名，有时根据违反约束的程度对候选解排名（对个体的决策是随机的）
- 在比较两个个体 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 时，**认为 $\mathbf{x}_1$ 优于 $\mathbf{x}_2$** ，如果：
  - 1) 这两个解都可行且 $f(\mathbf{x}_1) < f(\mathbf{x}_2)$ ；或
  - 2) 随机生成的数 $r \sim U[0,1]$ 小于用户给定的概率 $P_f$ ，并且 $f(\mathbf{x}_1) < f(\mathbf{x}_2)$ ；或
  - 3) 上面的两个条件都不满足，但是 $\mathbf{x}_1$ 比 $\mathbf{x}_2$ 违反的约束少。

在对种群中所有个体进行比较和排序后，为生成下一代选择父代并进行交叉。对于大部分问题， $P_f \in (0.4, 0.5)$ 会比较好。



# 处理约束的常用方法

- 单目标/多目标进化优化中的约束处理

- 比较两个个体 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 的优劣

- 1)  $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 均为可行解;
- 2)  $\mathbf{x}_1$ 可行,  $\mathbf{x}_2$ 不可行 或  $\mathbf{x}_2$ 可行,  $\mathbf{x}_1$ 不可行 ;
- 3)  $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 均为不可行解。

## 单目标进化优化:

- 1) 选择适应度值更好的个体;
- 2) 选择可行个体;
- 3) 选择约束违背少的个体





# 处理约束的常用方法

- 单目标/多目标进化优化中的约束处理

多目标进化优化：

重新定义支配，如果 $\mathbf{x}_1$ 支配 $\mathbf{x}_2$ ，需满足以下任一条件：

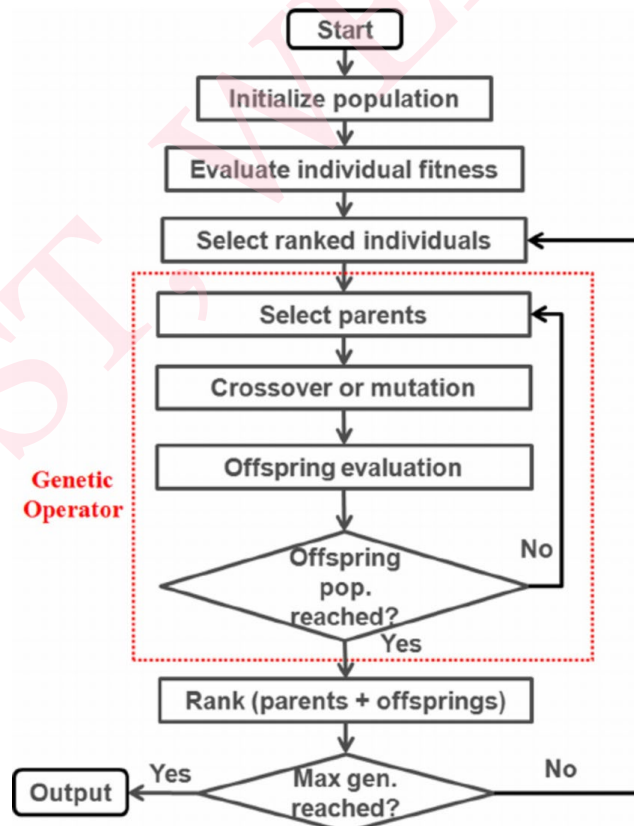
- 1)  $\mathbf{x}_1$ 可行， $\mathbf{x}_2$ 不可行；
- 2)  $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 均不可行，但 $\mathbf{x}_1$ 较少地违背约束；
- 3)  $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 均可行， $\mathbf{x}_1$ 支配 $\mathbf{x}_2$

# 处理约束的常用方法

- 单目标/多目标进化优化中的约束处理

多目标进化优化:

Constrained NSGA-II:





# 结束

---

